

計算科学における情報圧縮

Information Compression in Computational Science

**2018.9.27**

**#1:現代物理学における巨大なデータ**

**Huge data in modern physics**

---

理学系研究科 物理学専攻 大久保 毅

Department of Physics, **Tsuyoshi Okubo**

# Outline

---

- Background
  - Background of the lectures
  - Computational Science Alliance, The University of Tokyo
  - Computational science and data science
  - Tentative lecture schedule
  - Evaluation
- Huge data in physics
  - Why we need information compression?
  - Examples of information compression

# Background of lecturer

---

大久保 毅 (OKUBO Tsuyoshi)

Project Lecturer,  
Department of Physics,  
Sci. Bldg. #1 940

Research:

Statistical Physics, Condensed matter physics, Magnetism,  
(Computational Physics)

- Random packing of disks
- Mean-field analysis of hierarchical society
- Ordering of (classical) frustrated spin system
  - $Z_2$ -vortex, skyrmion, multiple-Q states, ...
- Deconfined quantum criticality
- **Tensor network methods**
- ....

# Background of Lecturers

山地 洋平 YAMAJI, Youhei (Project Associate Professor,  
Eng. Bldg. #6, 422)

Research:

Theoretical condensed matter physics

Computational method of many-body quantum systems

Developer of open source codes for supercomputers



Quantum lattice model solver  $H\Phi$

<http://ma.cms-initiative.jp/ja/index/ja/listapps/hphi>

# Computational Science Alliance, The University of Tokyo

---

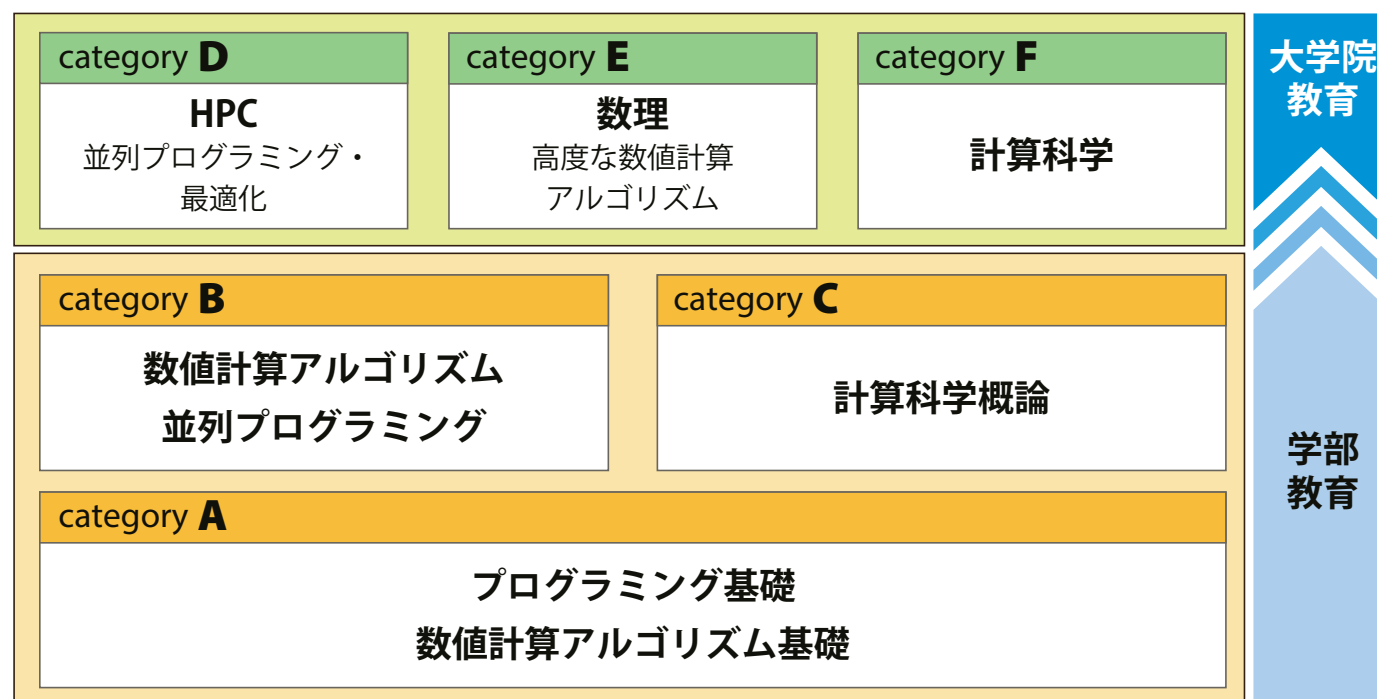


<http://www.compsci-alliance.jp>

Train experts for computational and computer sciences.

# 計算科学アライアンス認定講義

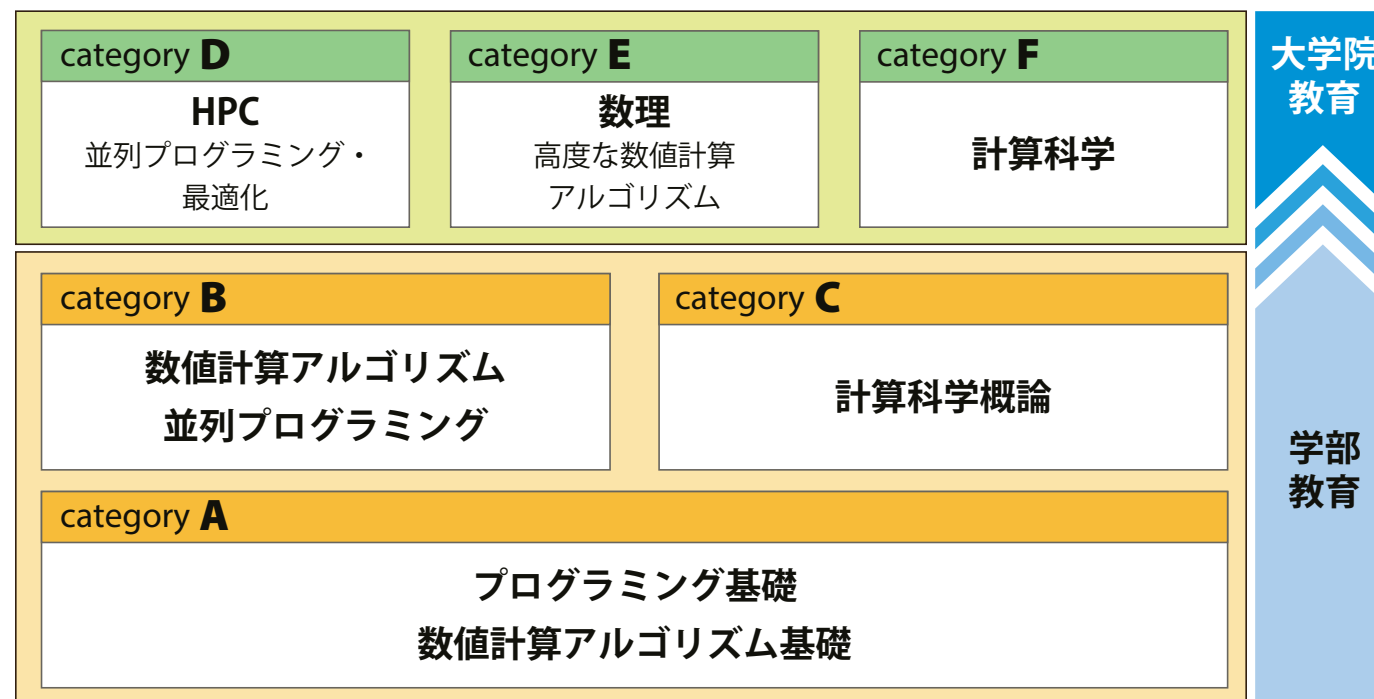
- 平成29年度から実習にも力点をおいた新しい講義を立ち上げ
- 計算科学・計算機科学に関する80以上の学部・大学院講義とあわせ、「計算科学アライアンス認定講義」として体系化
- 認定講義を内容に応じて6つのカテゴリに分類
- 所定の単位を取得した学生には「修了認定証」を発行
- この講義はカテゴリE



- 学部
  - カテゴリA,B,Cからそれぞれ1.5単位以上
- 大学院
  - カテゴリD,E,Fのうち2つのカテゴリを選択しそれぞれから2単位以上

# 計算科学アライアンス認定講義：大学院

- ・ カテゴリD - 最先端のスーパーコンピュータを駆使するのに必要とされる技術。種々の並列アルゴリズム、MPI並列やOpenMP並列などの並列プログラミング、メモリアクセス最適化などのチューニング
  - ・ 例：物質科学のための計算数理I
- ・ カテゴリE - 最先端の数値計算アルゴリズムとその数理的基礎付け。差分法・有限要素法・有限体積法、特異値分解、最適化問題などの手法とその応用
  - ・ 例：計算科学における情報圧縮
- ・ カテゴリF - 各分野におけるシミュレーション手法とその研究成果。電子状態計算、分子動力学、量子多体計算、数値流体力学、構造計算、ゲノム解析など
  - ・ 例：多体問題の計算科学、物質科学のための計算数理II



# 海外派遣

- 目的：国際的にトップクラスの計算科学・計算機科学の人材を育成する。
- 応募資格：東京大学に在籍する学部生・大学院生で、計算科学および計算機科学に関連する研究を行っているもの（登録者を優先）。
- 期間及び内容：1～2週間程度。 海外の国際会議における研究発表、サマースクール等への参加、大学・研究機関における国際共同研究など。
- 報告書：海外派遣終了後2週間以内にA4紙1枚以上（写真貼付可）を提出。
- 随時募集。
- 募集要項と応募申込書は計算科学アライアンスのWebページに掲載済み。  
<http://www.compsci-alliance.jp/overseas-support/>
- 昨年度は10件実施。



# 海外派遣

所属	学年	渡航先	日程
工学系研究科	博士 1 年	29th European Summer School in Logic, Language, and Information, Toulouse, France	2017.7.15 - 7.31
情報理工学系研究科	博士 1 年	SC17, Denver, USA	2017.11.11 - 11.18
理学系研究科	博士 1 年	2nd WCRP summer school on Climate Model Development, Cachoeira Paulista, Brazil	2018.1.20 - 2.3
理学系研究科	修士 1 年	University of Milan, Milan, Italy	2018.1.29 - 2.12
理学系研究科	修士 1 年	University of Milan, Milan, Italy	2018.1.29 - 2.12
理学系研究科	修士 1 年	University of Milan, Milan, Italy	2018.1.29 - 2.12
理学系研究科	博士 1 年	Marbug, Germany - Zurich, Switzerland - LA, USA	2018.2.18 - 3.11
工学系研究科	修士 2 年	APS March Meeting, Los Angeles, USA	2018.3.4 - 3.11
工学系研究科	博士 2 年	APS March Meeting, Los Angeles, USA	2018.3.4 - 3.11
理学系研究科	博士 1 年	APS March Meeting, Los Angeles, USA	2018.3.4 - 3.11

# Lecture schedule

---

Okubo	第1回：	現代物理学における巨大なデータ
	第2回：	現代物理学と情報圧縮
	第3回：	情報圧縮の数理1 (線形代数の復習)
	第4回：	情報圧縮の数理2 (特異値分解と低ランク近似)
	第5回：	情報圧縮の数理3 (スパース・モデリングの基礎)
Yamaji	第6回：	情報圧縮の数理4 (クリロフ部分空間法の基礎)
	第7回：	物質科学における情報圧縮
	第8回：	データ解析の高速化：スパース・モデリングの物質科学への応用
	第9回：	データ空間の圧縮：クリロフ部分空間法の物質科学への応用
Okubo	第10回：	高度なデータ圧縮：情報のエンタングルメントと行列積表現
	第11回：	行列積表現の固有値問題への応用
	第12回：	テンソルネットワーク表現への発展
	第13回：	テンソルネットワーク繰り込みによる情報圧縮

# Important informations

---

**Evaluation:** Based on 3 reports:

Exercise include algorithms and computer simulations.

(We provably provide **python codes**.)

**Notice!**

The grade will be evaluated based on  
**the sum of scores of three reports.**

(So, if you will miss one of them, it will be a big disadvantage.)

**Slides:**

The lecture slides will be uploaded to

- ITC-LMS (Information Technology Center Learning Management System)
- <https://github.com/compsci-alliance/information-compression>

Huge data in physics

# Computer science and data science

---

1. Experimental Science
2. Theoretical Science
3. Computational Science
4. Data Science
5. AI?

"Information compression in computational science"  
is related to 3rd and 4th sciences.  
(It might be slightly related to AI.)

# Huge data in physics

---

## Many-body problems in physics

- Celestial movement (天体運動)
- Gases, Liquids
- Molecules, Polymers (eg. Proteins), ...
- Electrons in molecules and solids
- Elemental particles (Quantum Chromo Dynamics)  
(量子色力学)

In these problems, "systems" contain huge degrees of freedoms:

$6N$ -dimensional phase space for classical mechanics

$O(e^N)$ -dimensional Hilbert space for quantum system



# Complex particle system

Eg. Poliovirus capsid in electrolyte solution

(ポリオウイルス カプシド)

(電解質溶液)


Y. Ando et al, J. Chem. Phys. **141**, 165101(2014).

Long-range coulomb interaction


(クーロン相互作用)

Poliovirus capsid

Dynamics of water molecules



6.5 million atoms





# Localized electrons as quantum spin systems

Eg. Antiferromagnetic Mott insulator  $\text{Na}_2\text{IrO}_3$   
(反強磁性) (モット絶縁体)

Y. Singh and P. Gegenwart, Physical Review B **82**, 064412 (2010)

$$\mathcal{H} = \sum_{i,j} J_{ij} S_i S_j$$

$S_i$  : spin operator






# Why we need information compression?

---

1. We can not understand huge information directly



We try to characterize "systems" thorough a few parameters

Examples:

## Thermodynamics:

Systems are characterized by thermodynamic quantities,  
Internal energy, Entropy, Pressure, Volume, Particle number,...

## Critical phenomena:


Critical systems are characterized by a few critical exponents.  
(臨界指数)

Related topics in 13th lecture: "Renormalization (繰り込み)"

# Why we need information compression?

---

1. We can not understand huge information directly



We try to characterize "systems" thorough a few parameters

Modeling:

We want to determine "essential" parameters to explain observed phenomena.

Occam's razor:

In order to understand the essence, we should not assume too much things.

William of Ockham



(from wikipedia)

Related topics in 5th and 8th lectures: "Sparse Modeling"

# Example of sparse modeling (Compressed sensing)

Reconstruction of MRI image  
from **smaller samplings**

M. Lustig et al, Magnetic Resonance in Medicine **58**, 1182 (2007).

Experiment: Random sampling in k-space




Image reconstruction by assuming  
**sparsity in wavelet transform domain**

$$\text{minimize } \|\Psi m\|_1$$

$$\text{s.t. } \|\mathcal{F}_u m - y\|_2 < \epsilon$$

$m$  :image

$\Psi$  :wavelet transform

$\mathcal{F}_u$  :Fourier transform

$y$  :Experimental data in k-space

$$\text{L}_1 \text{ norm: } \|x\|_1 = \sum_i |x_i|$$

$$\text{L}_2 \text{ norm: } \|x\|_2 = \sqrt{\sum_i |x_i|^2}$$

Acceleration

Low resolution

Zero-fill

Sparse modeling

x20

x10

x8

x6.7

x5

x1

x1

x10


Original  
(full sampling)

Slice

low-res

low-"SNR"

high-SNR  
high-res



# Why we need information compression?

---

## 2. We can not treat entire data in the present computers

### Available memories in the present computers

	Double precision real number = 8 Byte
Personal computers: ~10 GB	$\sim 10^9$
Super computers: ~100 GB / node	$\sim 10^{10}$
<b>K@RIKEN,</b> <b>Oakforest-PACS@UTokyo</b> and Tsukuba Univ, <b>Sekirei@ISSP, UTokyo</b> ...	~1 PB (whole system) $\sim 10^{14}$

**Notice:** In quantum system, the size of Hilbert space is  $O(e^N)$

# Why we need information compression?

---

2. We can not treat entire data in the present computers

 Try to reduce the "effective" dimension of (Hilbert) space

By taking proper basis set,  
we can represent a quantum state efficiently.

- Krylov subspace (6th and 9th lectures)
- Matrix product state (10th, 11th 12th lectures)
- Tensor network states
- ...

# Examples of information compression 1

---

## Krylov subspace


linear subspace generated by a square matrix ( $M$ ) and a vector ( $v$ ) as

$$\mathcal{K}_n(M, \vec{v}) = \text{span} \{ \vec{v}, M\vec{v}, M^2\vec{v}, \dots, M^{n-1}\vec{v} \}$$

For quantum many body problems:

$$M = \mathcal{H} \quad \text{:Hamiltonian}$$

$$\vec{v} = |\phi\rangle \quad \text{:wavevector}$$



Solve the eigenvalue problem within  
a restricted space (Krylov subspace)

**Lanczos method, Arnoldi method**

\* In these method, we do not necessarily need explicit matrix.  
It is enough to know the result of matrix vector multiplication.

# Examples of information compression 2

---

## Compression of an image


image = matrix

Original



$\chi = 768$

# of "singular values"



Compressed



$\chi = 10$



$\chi = 100$



# Examples of information compression 2

## Compression of a color image


About 20% compressed

image = tensor

Original



$\chi = 768$



SVD



HOSVD



# Singular value decomposition (特異値分解)

---

Singular value decomposition (SVD):

$U, V^\dagger$  : (half) unitary

For a  $K \times L$  matrix  $M$ ,

$\Lambda$  : Diagonal

$$M = U \Lambda V^\dagger$$

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_N \end{pmatrix}$$

$$M_{i,j} = \sum_m U_{i,m} \lambda_m V_{m,j}^\dagger$$

Singular values:  $\lambda_m \geq 0$

Singular vectors:  $\sum_m U_{i,m} U_{m,j}^\dagger = \delta_{i,j}$   
 $\sum_m V_{i,m} V_{m,j}^\dagger = \delta_{i,j}$

By taking only several larger singular values,  
we can approximate  $M$  as a lower rank matrix.

# Examples of information compression 3

Wave function:  $|\Psi\rangle = \sum_{\substack{\{m_i=\uparrow\downarrow\} \\ \text{or} \\ \{m_i=0,1\}}} T_{m_1,m_2,\dots,m_N} |m_1,m_2,\dots,m_N\rangle$

(波動関数)

$T_{m_1,m_2,\dots,m_N}$  N-rank tensor  
(or Vector)

# of Elements =  $2^N$





Approximation as  
a product of "matrices"

Matrix Product States (行列積状態)  
(Tensor train decomposition)

$$T_{m_1,m_2,\dots,m_N} \simeq A_1[m_1]A_2[m_2]\cdots A_N[m_N]$$


$A[m]$  : Matrix for state m



$$\begin{array}{c} i \quad j \\ \bullet \\ | \\ m \end{array} = A_{i,j}[m]$$


# Examples of tensor decompositions

**MPS:**




Good for 1d gapped systems  
(1d correlation in data)

**PEPS, TPS:**



For higher dimensional systems  
Extension of MPS  
(higher correlation in data)



**MERA:**



Scale invariant systems  
(スケール不変)

# Real space renormalization (実空間繰り込み)

Coarse graining of a tensor network



# Next week

---

第1回： 現代物理学における巨大なデータ

## 第2回： 現代物理学と情報圧縮

### (Information compression in modern physics)

第3回： 情報圧縮の数理1 (線形代数の復習)

第4回： 情報圧縮の数理2 (特異値分解と低ランク近似)

第5回： 情報圧縮の数理3 (スパース・モデリングの基礎)

第6回： 情報圧縮の数理4 (クリロフ部分空間法の基礎)

第7回： 物質科学における情報圧縮

第8回： データ解析の高速化：スパース・モデリングの物質科学への応用

第9回： データ空間の圧縮：クリロフ部分空間法の物質科学への応用

第10回： 高度なデータ圧縮：情報のエンタングルメントと行列積表現

第11回： 行列積表現の固有値問題への応用

第12回： テンソルネットワーク表現への発展

第13回： テンソルネットワーク繰り込みによる情報圧縮